

FUNDAMENTOS MATEMÁTICOS

CÁLCULO VARIACIONAL



DIEGO GONZÁLEZ OVIAÑO

1. INTRODUCCIÓN

En esta práctica se busca la implementación de técnicas de cálculo variacional a problemas cotidianos, ya sean la eliminación de marcas de agua o la eliminación de ruido en una fotografía nocturnas.

Se eligen una serie de ejercicios propuestos y se argumenta tanto matemáticamente como visualmente los resultados obtenidos.

2. LISTADO DE EJERCICIOS

A continuación, se desglosan las tareas tanto de denoising como de inpainting para diferentes hiperparámetros.

a. Denoising Lineal $p = 2, \lambda > 0$

La motivación para la realización de este ejercicio reside en la dificultad de obtener fotografías nocturnas de calidad con móviles de gama media. Es un problema que personalmente encuentro al realizar turismo y en especial al querer fotografiar elementos lejanos sin luz.

Por tanto, se decide tratar una imagen del viaje que realicé a Granada. Esta fotografía cumple los requisitos comentados: una fotografía nocturna de un objeto lejano. Asimismo, se puede observar que la calidad no es muy buena debido al propio ruido (*Figura 1*).

El objetivo será, primero, dañar una imagen con un ruido aleatorio y restaurar dicha imagen, y segundo, suponer que la imagen original es la imagen dañada y valorar si se el algoritmo reduce el ruido y mejora la calidad de la imagen.



Figura 1: Imagen original obtenida desde un móvil de gama media.

El modelo se basa en minimizar un funcional de energía (1) en donde el término Prior promueve la suavidad de la solución u minimizando las variaciones espaciales.

$$E(u) = \text{Prior}(u) + \lambda \cdot \text{Fidelity}(u, f) \quad (1)$$

El término de la fidelidad representa la confianza que se tiene en los datos originales y penaliza cualquier desviación excesiva de u respecto de f . Por tanto, si la fidelidad es grande, u se ajusta más a f y si es baja, u prioriza la suavidad y se aleja más de f . En el código, la fidelidad está integrada en el cálculo del gradiente del funcional (2).

$$\text{grad}_E(u) = -\Delta u + \lambda(u - f) \quad (2)$$

De forma más sencilla, calcular la u , la imagen restaurada, es la solución del problema del problema de minimización (3).

$$u = \arg \min_u E(u) \quad (3)$$

Comenzando con la resolución del ejercicio, cargamos la imagen y se deteriora con un ruido aleatorio de distribución normal (Figura 2).




Figura 2: Imagen original (izq), ruido generado (mdl) e imagen ruidosa (drch).

Una vez obtenida la imagen ruidosa se seleccionan los parámetros para la difusión lineal. En este caso $p = 2$ y $\lambda = 0.5$. Dicha difusión lineal aplica un bucle iterativo en donde calcula el descenso del gradiente para reducir el funcional de $E(u)$. Se calcula el gradiente de u , que mide el cambio de la intensidad de la imagen, el laplaciano de u , que mide la divergencia de los gradientes y suaviza las regiones de la imagen y se calcula el gradiente del funcional. Por último, se actualiza u que corresponde a resolver la ecuación de difusión (3).

$$\frac{\partial u}{\partial t} = \Delta u - \lambda \cdot (u - f) \quad (3)$$

Para este ejercicio no se ha implementado un criterio específico de parada, tan solo las iteraciones. A medida que se itera, se reduce el ruido de la imagen y u converge hacia una imagen que minimiza el compromiso entre suavidad y fidelidad.

Los resultados muestran una gráfica dinámica donde se visualiza la energía total, suma del prior y la fidelidad, la fidelidad y el prior. Además, se muestra cómo la PSNR aumenta, ya que a medida que avanzan las iteraciones la imagen resultante consta de menor ruido (*Figura 3*).




Figura 3: Visualización del algoritmo de eliminación del ruido.

En la *Figura 4* se muestran los resultados obtenidos tras aplicar denoising lineal.



Figura 4: Resultados de la difusión lineal.

Los resultados muestran cómo se reconstruye la imagen, sin embargo, no se está interesado en reconstruir una imagen, sino en mejorar la calidad de una foto tomada. Para ello se define un nuevo algoritmo, similar al anterior, pero implementando un criterio de parada. Al querer reducir el ruido de una imagen con la ecuación de difusión, se calcula la energía total por cada iteración, en el momento en que la diferencia de dicha energía entre iteraciones consecutivas es menor que un cierto umbral, se concluye que ha convergido (4).

$$\Delta E = \left| E^{(k+1)} - E^{(k)} \right| \quad (4)$$

En este caso, al no tener la imagen original no se puede calcular la PSNR. En la *Figura 5* se muestra las gráficas durante el procesamiento de denoising.




Figura 5: Gráficas de denoising con criterio de parada.

Por último, se representan los resultados en la *Figura 6*. Se puede observar como el algoritmo ha eliminado parte del ruido, pero ha comprometido la resolución de los bordes y siluetas importantes. Para mejorar dicha problemática se puede reducir λ para confiar menos en los datos de la imagen y provocar un menor suavizado o realizar denoising no lineal con $p = 1$. Dicho uso provocaría una difusión no lineal donde, debido a una serie de condiciones, reduce el ruido preservando los bordes.

La solución con $p = 1$ se abordará en el siguiente ejercicio mencionado.



Figura 6: Resultados obtenidos tras denoising de imagen original.

b. Denoising No Lineal $\lambda > 0, p > 0$

Al usar $p = 1$, se convierte en una difusión no lineal que convierte el término Prior en la variación total de u (5). Esto permite realizar una difusión anisotrópica, actuando de manera diferente en cada punto, preservando los bordes y eliminando el ruido en las áreas más suaves.

$$E(u) = \frac{1}{p} \int_{\Omega} |\nabla u|^p dx + \lambda \cdot \frac{1}{2} \int_{\Omega} (u - f)^2 dx \quad (5)$$

Como limitación, destaca la alta complejidad numérica, y, por tanto, las elevadas demandas computacionales. Necesita de mayores tiempos de ejecución para converger. En este caso, se utiliza el mismo algoritmo de parada comentado anteriormente y se sitúa el umbral del error en $1e^{-7}$.

Frente a las 300 iteraciones aproximadas que necesitaba el algoritmo con $p = 2$ para converger, con $p = 1$ necesita cerca de 1000. En la *Figura 7* se muestran los resultados obtenidos.




Figura 7: Resultados obtenidos de la difusión no lineal.

Se observa que suaviza peor, pero que mantiene mejor la resolución de los bordes. Se considera que con un ajuste de parámetros óptimos, la implementación de $p = 1$ en este contexto no refleja soluciones significativas para la diferencia respecto a las demandas computacionales que supone. Se adjunta en la *Figura 8* la comparación de los resultados.




Figura 8: Resultados del denoising para distintas p .

c. Inpainting Lineal $p = 2$

Para la realización de este ejercicio se establece como contexto la eliminación de las marcas de agua. Muchas veces dificultan la visión de una imagen y empeoran el resultado. De tal manera, se introduce la ecuación de difusión del calor, que es un caso concreto de difusión. Por tanto, el fundamento matemático es similar al denoising, se busca que la información de la imagen difunda de los píxeles con información a la máscara, en este caso definida como píxeles en negro.

El algoritmo utiliza un esquema iterativo para resolver el problema (6).

$$u^{(k+1)} = u^{(k)} - dt \cdot \nabla E(u^{(k)}) \quad (6)$$

De tal forma, se deberá definir una máscara de píxeles negros que correspondan a la marca de agua que se busca eliminar. Para ello se carga la imagen a procesar (*Figura 9*), se normaliza y se seleccionan aquellos píxeles que superan un valor de 0.88. Dichos píxeles corresponderán a la marca de agua que se desea eliminar.



Figura 9: Imagen con marca de agua.

Posteriormente, para asegurarse de que se ha seleccionado toda la marca de agua se realizan operaciones morfológicas de dilatación y se define la máscara en color negro. Por último, se multiplica la imagen de entrada por dicha máscara para obtener la imagen lista para introducir al algoritmo (*Figura 10*).




Figura 10: Imagen original junto con la imagen máscara de píxeles negros.

En este contexto, es importante definir el peso de la fidelidad. Es decir, la importancia que se le da a los píxeles que no son negros. Se ejecuta el algoritmo con $p = 2$ y tras 4000 iteraciones se obtienen los resultados mostrados en la *Figura 11*.




Figura 11: Resultados de inpating con $p = 2$.

Se observa que elimina correctamente la marca de agua generando un resultado prácticamente imperceptible para la visión humana. Se decide probar el inpating no lineal para valorar los resultados.

d. Inpainting No Lineal $p = 1$

En la *Figura 10* se observan los resultados del inpating no lineal. En este caso se ha reducido el valor de la fidelidad, para reducir el tiempo de ejecución, por lo que los resultados se ven más borrosos, sin embargo, al usar $p = 1$ se deberían obtener unos resultados mejores. Se concluye que con una elección de parámetros óptima se preservarían los bordes.




Figura 12: Resultados de inpating con $p = 1$

3. CONCLUSIONES

Se concluye que el uso del cálculo variacional se puede aplicar en técnicas de la vida cotidiana para mejorar la visualización de imágenes. De este proyecto se podrían seguir implementando funciones tales como la pérdida de información, ya que es lo mismo que el inpating salvo por la máscara generada.